In [17]:
```
# імпортуємо бібліотеку   pandas
import pandas as pd
```

In [18]:
```
# зчитуємо CSV-файли в Pandas і завантажуємо в таблиці df  і df1
df = pd.read_csv(r'D:\GO_IT\Проєкт2\survey_results_public.csv', encoding='UTF-8'
df1 = pd.read_csv(r'D:\GO_IT\Проєкт2\survey_results_schema.csv', encoding='UTF-8
#df.shape[0]
```

```
C:\Users\M&S\AppData\Local\Temp\ipykernel_21748\3432534420.py:2: DtypeWarning: Co
lumns (56,74,92,97,98,105,109,110,132,162,165) have mixed types. Specify dtype op
tion on import or set low_memory=False.
  df = pd.read_csv(r'D:\GO_IT\Проєкт2\survey_results_public.csv', encoding='UTF-
8')
```

In [19]:
```
#налаштування параметрів для відображення всіх колонок
pd.set_option('display.max_column',None)
```

In [20]:
```
# Завдання 1. Підрахунок загальної кількості респондентів
respondents_count = df['ResponseId'].nunique()
respondents_count
```

Out[20]: 49191

In [7]:
```
# df.shape[0] == df['ResponseId'].nunique()
# немає дублікатів:
```

In [21]:
```
#Завдання 2. Аналіз повноти відповідей респондентів
# Створюємо множину назв питань з колонки 'qname' (уникальні)
questions_set = set(df1['qname'].dropna().unique())
# Обираємо лише ті питання, які реально є у нашому датафреймі
existing_questions = questions_set.intersection(df.columns)
# Видаляємо рядки, де є пропуски у цих колонках
complete_respondents = df[list(existing_questions)].dropna()
# Кількість респондентів, які відповіли на всі питання
num_complete_respondents = complete_respondents.shape[0]
num_complete_respondents
```

Out[21]: 0

In [22]:
```
#№Завдання 3. Статистичний аналіз досвіду респондентів
# Вибираємо колонку з досвідом роботи
work_exp = df['WorkExp']
# Обчислюємо статистичні показники, пропускаючи пропущені значення  NaN
mean_exp = work_exp.mean(skipna=True).round(2)
median_exp = work_exp.median(skipna=True)
mode_exp = work_exp.mode(dropna=True)
# Виводимо результат
print(f"Міри центральної тенденції для досвіду роботи респондентів:")
print(f"Середнє значення (mean): {mean_exp}")
print(f"Медіана (median): {median_exp}")
print(f"Мода (mode): {list(mode_exp)}")
```

```
Міри центральної тенденції для досвіду роботи респондентів:
Середнє значення (mean): 13.37
Медіана (median): 10.0
Мода (mode): [10.0]
```

In [10]:
```
#Завдання 4. Аналіз віддаленої роботи
# Підрахунок респондентів, які працюють віддалено (Remote)
remote_count = (df['RemoteWork'] == 'Remote').sum()
print(remote_count)
```

```
10931
```

In [11]:
```
#Завдання 5. Визначення популярності Python
# Створюємо копію датафрейму
df_copy = df.copy()
# Створюємо новий стовпець Worked with Python
df_copy["Worked with Python"] = df_copy["LanguageHaveWorkedWith"] \
    .str.contains("Python", case=False, na=False)
# Кількість респондентів, які працювали з Python
python_count = df_copy["Worked with Python"].sum()
# Загальна кількість респондентів
total_count = len(df_copy)
# Відсоток респондентів, які програмують на Python
ВідсотокРеспондентів = python_count / total_count * 100
print(f"{ВідсотокРеспондентів:.1f}%")
```

```
37.5%
```

In [23]:
```
#Завдання 6. Аналіз шляхів навчання програмуванню
# Працюємо з копією датафрейму
df_copy = df.copy()
# Створюємо новий стовпець: чи навчався респондент через онлайн-курси
df_copy["Learned with online courses"] = df_copy["LearnCode"] \
    .str.contains("Online courses", case=False, na=False)
# Підраховуємо кількість таких респондентів
online_courses_count = df_copy["Learned with online courses"].sum()
print(f"Кількість респондентів, які навчались через онлайн-курси: {online_course
```

```
Кількість респондентів, які навчались через онлайн-курси: 10973
```

In [13]:
```
#Завдання 7. Географічний аналіз компенсації Python-розробників

df_copy = df.copy()
# Відбір респондентів, які працювали з Python
python_devs = df_copy[
    df_copy["LanguageHaveWorkedWith"]
    .str.contains("Python", case=False, na=False)
]
# Видаляємо рядки без інформації про компенсацію
python_devs = python_devs.dropna(subset=["ConvertedCompYearly"])
# Групування за країнами та розрахунок статистик
salary_by_country = (
    python_devs
    .groupby("Country")["ConvertedCompYearly"]
    .agg(
        avg_compensation="mean",
        median_compensation="median",
        respondents_count="count"   # додатково: кількість Python-розробників у
    )
    .reset_index()
)
# Округлення значень для кращої читабельності
salary_by_country["avg_compensation"] = salary_by_country["avg_compensation"].ro
salary_by_country["median_compensation"] = salary_by_country["median_compensatio
# Сортування за середньою компенсацією (за спаданням)
```

```
salary_by_country = salary_by_country.sort_values(by="avg_compensation", ascendi
salary_by_country
```

Out[13]:

	Country	avg_compensation	median_compensation	respondents_count
102	Oman	390135.00	390135.0	2
3	Andorra	226103.50	226103.5	2
149	Viet Nam	218837.17	8254.0	30
145	United States of America	173298.59	150000.0	3126
132	Switzerland	156456.60	142592.0	240
...	...	...	...	...
20	Botswana	1277.00	1277.0	1
24	Cambodia	1270.00	1270.0	1
136	Togo	354.00	354.0	1
104	Palestine	78.00	78.0	1
4	Antigua and Barbuda	1.00	1.0	1

153 rows × 4 columns

In [14]:

```
#Завдання 8. Аналіз освіти найбільш оплачуваних спеціалістів
# Працюємо з копією датафрейму
df_copy = df.copy()
# бираємо потрібні колонки
cols = ["ResponseId", "EdLevel", "ConvertedCompYearly"]
df_selected = df_copy[cols]
# Видаляємо рядки без значення зарплати
df_selected = df_selected.dropna(subset=["ConvertedCompYearly"])
# Сортуємо за компенсацією (за спаданням)
df_sorted = df_selected.sort_values(by="ConvertedCompYearly", ascending=False)
# Оновлюємо індекс
df_sorted = df_sorted.reset_index(drop=True)
# Обираємо топ-5 респондентів
top5_education = df_sorted.head(5)
# Виводимо результат
top5_education
```

Out[14]:

	ResponseId	EdLevel	ConvertedCompYearly
0	34268	Associate degree (A.A., A.S., etc.)	50000000.0
1	28701	Master's degree (M.A., M.S., M.Eng., MBA, etc.)	33552715.0
2	43144	Associate degree (A.A., A.S., etc.)	18387548.0
3	35354	Bachelor's degree (B.A., B.S., B.Eng., etc.)	15430267.0
4	45972	Master's degree (M.A., M.S., M.Eng., MBA, etc.)	13921760.0

In [15]:
```
#Завдання 9. Аналіз популярності Python по віковим категоріям

df_copy = df.copy()
# Створюємо колонку: чи працював респондент з Python
df_copy["PythonUser"] = (
    df_copy["LanguageHaveWorkedWith"]
    .str.contains("Python", case=False, na=False)
)
# Групування по вікових категоріях
age_python_stats = (
    df_copy
    .groupby("Age")["PythonUser"]
    .mean() * 100   # mean() = частка True → множимо на 100 для %
)
# Перетворюємо в DataFrame
age_python_stats = age_python_stats.reset_index()
# Перейменовуємо колонки
age_python_stats.columns = ["Вікова категорія", "Відсоток Python-розробників"]
# Округлюємо відсотки
age_python_stats["Відсоток Python-розробників"] = age_python_stats["Відсоток Pyt
# Виводимо результат
age_python_stats.sort_values(by="Відсоток Python-розробників", ascending=False)
```

Out[15]:

	Вікова категорія	Відсоток Python-розробників
0	18-24 years old	40.00
3	45-54 years old	38.63
4	55-64 years old	37.24
1	25-34 years old	36.94
2	35-44 years old	36.72
5	65 years or older	31.63
6	Prefer not to say	31.22

In [24]:
```
#Завдання 10. Аналіз індустрій серед високооплачуваних віддалених працівників

df_copy = df.copy()
# Видаляємо рядки без зарплати
df_copy = df_copy.dropna(subset=["ConvertedCompYearly"])

# Обчислюємо 75-й перцентиль компенсації
percentile_75 = df_copy["ConvertedCompYearly"].quantile(0.75)
print(f"75-й перцентиль компенсації: {percentile_75:,.0f}")
# Фільтруємо високооплачуваних віддалених працівників
high_paid_remote = df_copy[
    (df_copy["ConvertedCompYearly"] > percentile_75) &
    (df_copy["RemoteWork"] == "Remote")
]
# Підраховуємо популярність індустрій
industry_stats = (
    high_paid_remote["Industry"]
    .value_counts()
    .reset_index()
)
# Перейменовуємо колонки
```

```
industry_stats.columns = ["Індустрія", "Кількість респондентів"]
# Виводимо результат
industry_stats
```

```
75-й перцентиль компенсації: 120,596
```

Out[24]:

	Індустрія	Кількість респондентів
0	Software Development	1186
1	Fintech	190
2	Healthcare	188
3	Other:	176
4	Internet, Telecomm or Information Services	138
5	Banking/Financial Services	88
6	Government	78
7	Media & Advertising Services	75
8	Retail and Consumer Services	65
9	Transportation, or Supply Chain	63
10	Computer Systems Design and Services	59
11	Insurance	46
12	Energy	45
13	Manufacturing	33
14	Higher Education	30

In [ ]: